
CERTIFICATION PROFESSIONNELLE — EXPERT EN INFORMATIQUE ET
SYSTÈME D'INFORMATION — RNCP35584

Bloc 3 — Piloter l'informatique décisionnel d'un S.I (Big Data & Business Intelligence)

MSPR — Big Data et Analyse de données

Rapport de synthèse

*Analyse prédictive des tendances électorales
par indicateurs socio-économiques*

Preuve de Concept (POC) — Client : **Electio-Analytics**

Équipe projet

Nom Prénom
Stephane DOUNGUE
Kelly TSANGA
Sara HADDAD
Lamiaa KHALIL
Sofiane CHELGHOUM

Encadrant pédagogique : Ali Zahaf

Promotion : I1 EISI — 2025/2026

Date de soutenance : Juin 2026

Document confidentiel — usage pédagogique uniquement

Table des matières

Table des figures	iv
Introduction générale	1
1 Choix géographique	4
1.1 Zone retenue : la région Nouvelle-Aquitaine	4
1.2 Justification du choix	4
1.2.1 Disponibilité des données	4
1.2.2 Représentativité	5
1.2.3 Taille exploitable	5
2 Données et indicateurs	6
2.1 Sources de données utilisées	6
2.2 Indicateurs retenus	6
2.2.1 Données électorales (variable cible)	6
2.2.2 Données de sécurité — la variable la plus déterminante	7
2.2.3 Démographie et population	7
2.2.4 Emploi et activité économique	7
2.2.5 Logement	8
2.2.6 Données territoriales complémentaires	8
2.3 Récapitulatif des variables et leur importance	8
3 Architecture et pipeline de données	9
3.1 Vue d'ensemble de l'architecture	9
3.2 Pipeline ETL détaillé	11
3.2.1 Phase 1–2 : Extraction et fusion des sources	11
3.2.2 Phase 3 : Normalisation des orientations politiques	11
3.2.3 Phase 4 : Nettoyage des données	11
3.2.4 Phase 5 : Augmentation temporelle	11
3.2.5 Phase 6 : Feature Engineering	11
3.2.6 Phase 7 : Normalisation	12
3.2.7 Phase 8 : Chargement (Load)	12
3.3 Modèle Conceptuel de Données (MCD)	12
3.4 Nommage des tables et des champs	14
3.5 Conformité RGPD et gouvernance des données	14

4	Démarche et analyse exploratoire	15
4.1	Nettoyage des données	15
4.1.1	Traitement des valeurs manquantes	15
4.1.2	Suppression des doublons	15
4.1.3	Normalisation	16
4.1.4	Résultat après nettoyage	16
4.2	Analyse exploratoire	17
4.2.1	Visualisations descriptives	17
4.2.2	Corrélations entre indicateurs et résultats électoraux	18
4.3	Réponse à la question jury : quelle donnée est la plus corrélée aux résultats électoraux ?	19
4.3.1	Résultat	19
4.3.2	Interprétation	19
4.3.3	Confirmation par les variables complémentaires	19
5	Modèles de Machine Learning	20
5.1	Apprentissage supervisé — définition	20
5.2	Stratégie d'évaluation	20
5.2.1	Découpage train / test	20
5.2.2	Validation croisée 5-fold stratifiée	20
5.3	Algorithmes évalués	21
5.4	Modèle sélectionné : XGBoost	21
5.4.1	Hyperparamètres	21
5.4.2	Résultats de la validation croisée (5-fold)	22
5.4.3	Résultats sur l'ensemble de test	22
5.4.4	Performance par classe	22
5.4.5	Matrice de confusion	23
5.5	Normalisation des données d'entrée	23
6	Résultats	24
6.1	Choix du modèle final : XGBoost	24
6.2	Accuracy — définition et interprétation	24
6.2.1	Définition formelle	24
6.2.2	Application numérique	24
6.2.3	Limites de l'accuracy	25
6.3	Résultats sur la Nouvelle-Aquitaine	25
6.3.1	Niveau régional	25
6.3.2	Niveau départemental	25
6.4	Prédictions temporelles par scénario économique	26
6.4.1	Principe de projection	26
6.4.2	Projections à 1, 2 et 3 ans	27
6.4.3	Signaux économiques par scénario	28
6.4.4	Précision attendue des projections	28
7	Visualisations et interface utilisateur	30
7.1	Page principale — tableau de bord de prédictions	30
7.1.1	Navigation et filtres	30
7.1.2	Cartes KPI	31

7.1.3	Spectre politique dynamique	31
7.1.4	Tableau de prédictions	32
7.1.5	Graphiques en anneau (donuts)	33
7.2	Page visualisation — analyses graphiques	34
7.2.1	Carte géographique de la Nouvelle-Aquitaine	34
7.2.2	Matrice de corrélation interactive	34
7.2.3	Comparaison inter-modèles — BarChart et RadarChart	35
7.2.4	Courbes d'apprentissage	36
7.3	Stack technique de la couche visualisation	37
Conclusion et recommandations		38
	Bilan du POC	38
	Limites identifiées	38
	Recommandations pour le passage en production	39
Bibliographie		40
A Schéma du jeu de données nettoyé		41
B Extraits de code commentés		43

Table des figures

1	Tableau de suivi de projet (Trello) organisé selon les phases CRISP-DM	3
3.1	Schéma global du flux de données	10
3.2	Modèle Conceptuel de Données	13
4.1	Données électorales brutes avant nettoyage : 1 ^{er} tour 2017 par canton, avec les voix réelles par candidat (nombres entiers, non normalisés).	15
4.2	Extrait de la base finale d'entraînement après nettoyage et normalisation : variables d'entrée du modèle (en 0–1, dont la délinquance) et résultat réel utilisé uniquement pour la validation.	17
4.3	Importance des variables — modèle XGBoost (la délinquance en tête)	18
5.1	Matrice de confusion — XGBoost (jeu de test, 5 classes)	23
6.1	Projections temporelles à +1, +2 et +3 ans : indice économique régional projeté (haut) et composition du vote prédit selon les scénarios optimiste / neutre / pessimiste (bas).	28
7.1	Barre de filtres — sélecteur de modèle et filtre géographique	31
7.2	Cartes KPI — vainqueur prédit, état économique, accuracy	31
7.3	Spectre politique — état économique Stable, marqueur Centre	32
7.4	Tableau de prédictions — niveau Départements	33
7.5	Donuts — répartition réelle (gauche) vs prédite (droite)	34
7.6	Carte choroplèthe des 12 départements — probabilité MACRON prédite	34
7.7	Matrice de corrélation interactive — 8 variables	35
7.8	Gauche : BarChart comparatif (Accuracy). Droite : Radar multi-métriques.	36
7.9	Courbes d'apprentissage — XGBoost (accuracy et perte sur 100 itérations)	36

Introduction générale

Contexte

Electio-Analytics est une start-up fondée en 2017 par Jean-Édouard de la Motte-Rouge, spécialisée dans le conseil stratégique dédié aux campagnes électorales. Son activité consiste à fournir à ses clients — candidats, partis politiques et cabinets de conseil — des analyses prospectives précises, en exploitant des données publiques et privées.

Face à un marché électoral de plus en plus compétitif, la société souhaite se doter d’une capacité de prévision des tendances électorales à moyen terme, sur un horizon d’un à trois ans. Cette capacité reposerait sur l’analyse croisée d’indicateurs socio-économiques tels que le taux de chômage, la sécurité, la pauvreté, la densité de population ou encore le nombre d’entreprises actives sur un territoire.

Avant d’engager des investissements à grande échelle, Electio-Analytics a souhaité valider cette approche par une **preuve de concept (POC)**, confiée à notre équipe.

Objectifs du POC

Ce projet a pour objectifs de :

- Collecter et consolider des jeux de données publics pertinents sur un périmètre géographique restreint ;
- Mettre en place un pipeline ETL automatisé pour le nettoyage, la normalisation et le stockage des données ;
- Identifier les indicateurs socio-économiques les plus corrélés aux résultats électoraux historiques ;
- Construire et comparer plusieurs modèles de machine learning supervisé pour la prédiction des tendances électorales ;
- Présenter les résultats sous forme de visualisations accessibles, permettant une prise de décision stratégique rapide.

Périmètre du document

Ce rapport de synthèse couvre l’intégralité de la démarche réalisée dans le cadre du POC. Il présente successivement le choix géographique retenu, les données et indicateurs mobilisés, l’architecture technique mise en place, la démarche d’analyse exploratoire, les modèles de machine learning testés, les résultats obtenus ainsi que les visualisations produites.

Le périmètre géographique de l’étude est limité à la région **Nouvelle-Aquitaine**, conformément aux exigences du cahier des charges imposant un secteur unique et exploitable. Les données couvrent la période **2012–2022**, s’appuyant sur les résultats des élections présidentielles et sur des indicateurs socio-économiques issus de sources publiques (data.gouv.fr, INSEE, ministère de l’Intérieur).

Organisation et gestion de projet

Afin de garantir une démarche rigoureuse et reproductible, le projet a été structuré selon une méthodologie inspirée du standard **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*), qui décompose un projet de science des données en phases successives, de la compréhension du besoin métier jusqu’à la restitution des résultats. Cette organisation séquentielle a guidé l’ensemble de nos travaux et structure d’ailleurs le plan du présent rapport.

Phase CRISP-DM	Traduction dans le projet
1. Compréhension métier	Analyse du besoin client Electio-Analytics, définition de l’objectif de prédiction et de la variable cible
2. Compréhension des données	Collecte et exploration des sources publiques (élections, INSEE, délinquance, entreprises)
3. Préparation des données	Pipeline ETL : nettoyage, normalisation, feature engineering et stockage multi-format
4. Modélisation	Entraînement et réglage de cinq modèles de <i>machine learning</i> supervisé
5. Évaluation	Comparaison des modèles, validation croisée et sélection de l’algorithme retenu (XGBoost)
6. Déploiement	Tableau de bord interactif de visualisation des prédictions
7. Restitution	Rédaction du rapport de synthèse et préparation de la soutenance

TABLE 1 – Démarche projet structurée selon la méthodologie CRISP-DM

Le suivi et la coordination des tâches ont été assurés à l’aide de l’outil de gestion de projet **Trello**, organisé en tableau *Kanban* reprenant les différentes phases de la démarche (figure 1). Chaque carte y représente une tâche associée à un statut d’avancement, garantissant une visibilité partagée sur l’état du projet.



FIGURE 1 – Tableau de suivi de projet (Trello) organisé selon les phases CRISP-DM

Chapitre 1

Choix géographique

1.1 Zone retenue : la région Nouvelle-Aquitaine

Le périmètre géographique retenu pour cette preuve de concept est la région **Nouvelle-Aquitaine**. Créée en 2016 à la suite de la fusion des anciennes régions Aquitaine, Limousin et Poitou-Charentes, elle constitue la plus grande région de France métropolitaine avec une superficie de **84 061 km²**.

Elle regroupe **12 départements** :

Code	Département	Code	Département
16	Charente	33	Gironde
17	Charente-Maritime	40	Landes
19	Corrèze	47	Lot-et-Garonne
23	Creuse	64	Pyrénées-Atlantiques
24	Dordogne	79	Deux-Sèvres
87	Haute-Vienne	86	Vienne

TABLE 1.1 – Les 12 départements de la région Nouvelle-Aquitaine

La région compte environ **6 millions d’habitants** et plus de **127 cantons**, offrant ainsi une granularité géographique suffisante pour entraîner et valider un modèle prédictif.

1.2 Justification du choix

1.2.1 Disponibilité des données

La Nouvelle-Aquitaine bénéficie d’une couverture particulièrement riche sur les plateformes de données ouvertes. Les jeux de données utilisés dans ce projet sont intégralement issus de sources publiques et librement accessibles :

- **data.gouv.fr** : résultats électoraux des scrutins présidentiels de 2012, 2017 et 2022, à la maille commune et canton ;
- **INSEE** : indicateurs démographiques, économiques et sociaux (population, taux de chômage, revenus médians, nombre d’entreprises) ;
- **Données de sécurité** : statistiques de la délinquance par département (taux pour 1 000 habitants) issues du ministère de l’Intérieur, pour l’année 2016 ;
- **Indicateurs de pauvreté** : taux de pauvreté et allocataires des minima sociaux par territoire.

La disponibilité de ces données sur plusieurs années consécutives est un critère déterminant, car elle conditionne directement la qualité et la fiabilité des modèles de machine learning entraînés.

1.2.2 Représentativité

La Nouvelle-Aquitaine présente un profil socio-économique **particulièrement hétérogène**, ce qui en fait un terrain d'analyse représentatif à l'échelle nationale :

- Des zones **urbaines dynamiques** (Bordeaux, Poitiers, Limoges, Pau) avec un tissu économique dense ;
- Des territoires **ruraux et périurbains** (Creuse, Corrèze, Dordogne) marqués par le vieillissement démographique et la désertification économique ;
- Des zones **littorales** (Charente-Maritime, Landes) avec des dynamiques touristiques et immobilières spécifiques ;
- Une forte variabilité des résultats électoraux entre les scrutins de 2012, 2017 et 2022, offrant une diversité de cas d'entraînement.

Cette diversité interne permet au modèle d'apprendre sur des configurations socio-économiques variées, améliorant ainsi sa capacité de généralisation.

1.2.3 Taille exploitable

Avec 127 cantons et 12 départements, la région offre un volume de données **suffisant pour entraîner des modèles supervisés** tout en restant maîtrisable dans le cadre d'un POC. Un périmètre plus large (national) aurait considérablement alourdi le pipeline de traitement et complexifié l'interprétation des résultats, sans apporter de valeur supplémentaire à ce stade de validation.

Ce compromis entre volumétrie et exploitabilité est parfaitement aligné avec les exigences du cahier des charges, qui impose un secteur géographique *"restreint et unique"*.

Chapitre 2

Données et indicateurs

2.1 Sources de données utilisées

L'ensemble des données mobilisées dans ce projet est issu de sources publiques officielles, garantissant leur fiabilité, leur traçabilité et leur libre réutilisation. Deux grandes catégories de données ont été collectées : les **données électorales** (variable cible) et les **indicateurs socio-économiques** (variables explicatives).

Source	Contenu	Période couverte
data.gouv.fr	Résultats électoraux présidentiels (tour 1) à la maille canton	2012, 2017
INSEE	Données démographiques, emploi, logement, activité économique	2016, 2022
Ministère de l'Intérieur (data.gouv.fr)	Statistiques de la délinquance par département (taux pour 1 000 habitants)	2016
INSEE	Indicateurs économiques territoriaux (entreprises par secteur)	2023

TABLE 2.1 – Sources de données utilisées dans le projet

Les données électorales de **2022** ont été réservées exclusivement au jeu de test final, afin d'évaluer la capacité prédictive du modèle sur des données jamais vues lors de l'entraînement.

2.2 Indicateurs retenus

Les indicateurs ont été sélectionnés selon leur disponibilité à la maille cantonale ou départementale et leur pertinence vis-à-vis du comportement électoral. Le projet s'appuie sur **28 variables delta** — c'est-à-dire des *variations entre deux périodes* plutôt que des valeurs absolues — afin de capturer la dynamique territoriale plutôt qu'un état figé.

2.2.1 Données électorales (variable cible)

Les résultats des élections présidentielles au premier tour pour les scrutins de 2012 et 2017 constituent le jeu d'entraînement. Pour chaque canton, la variable cible est le **candidat arrivé**

en tête, recodé en orientation politique selon la table de correspondance suivante :

Candidat	Orientation politique
MACRON	Centre
BAYROU	Centre
LE PEN	Extrême Droite
ZEMMOUR	Extrême Droite
MÉLENCHON	Extrême Gauche
JOLY	Gauche
HAMON	Gauche
HOLLANDE	Gauche
FILLON	Droite
SARKOZY	Droite

TABLE 2.2 – Mapping candidats vers orientation politique

2.2.2 Données de sécurité — la variable la plus déterminante

Les statistiques de la délinquance, exprimées en **taux pour 1 000 habitants** à l'échelle départementale (source : ministère de l'Intérieur via data.gouv.fr), ont été intégrées au modèle sous la forme de la variable `delta_Delinquance`.

Contrairement à notre hypothèse initiale, cette variable s'est révélée être le **premier facteur prédictif du modèle**, avec une importance de **17,46%** — soit plus du double de la deuxième variable. Plus le taux de délinquance d'un territoire est élevé, plus le modèle l'oriente vers un état socio-économique dégradé et un vote de rupture. Ce résultat répond directement à la question du jury sur la variable la plus corrélée aux résultats électoraux (cf. chapitre 4).

Limite de granularité. La délinquance n'étant disponible qu'à l'échelle *départementale*, tous les cantons d'un même département reçoivent la même valeur. Cette granularité grossière explique certaines erreurs de prédiction au niveau cantonal (cf. chapitre 6, cas de la Gironde).

2.2.3 Démographie et population

Les variations démographiques figurent parmi les variables les plus importantes du modèle, juste derrière la délinquance.

- `delta_P22_POP1564` — variation de la population en âge de travailler (15–64 ans) (importance : **7.75%**, 2^e facteur du modèle)
- `delta_P16_POP` — variation de la population totale (importance : **6.21%**, 3^e facteur du modèle)
- `delta_P22_MEN` — variation du nombre de ménages

Un territoire en déclin démographique tend à orienter son vote vers des candidatures protestataires, tandis qu'une croissance de population est associée à une stabilité ou un vote centriste.

2.2.4 Emploi et activité économique

- `delta_P22_ACT1564` — variation des actifs 15–64 ans (importance : **4.63%**)
- `delta_P22_EMPLT` — variation du nombre d'emplois

- `delta_P22_EMPLT_SAL` — variation des emplois salariés
- `ETT0T23`, `ETAZ23`, `ETBE23`, `ETFZ23`, `ETGU23`, `ET0Q23` — nombre d'établissements actifs par secteur d'activité (industrie, commerce, services, etc.)

La baisse du nombre d'actifs et d'emplois salariés est un indicateur fort de fragilité économique territoriale, corrélée historiquement au vote protestataire.

2.2.5 Logement

- `delta_P22_LOGVAC` — variation des logements vacants (importance : **5.76%**)
- `delta_P22_LOG` — variation du parc de logements totaux (importance : **5.75%**)
- `delta_P22_RP` — variation des résidences principales

L'augmentation des logements vacants est un signal de dépeuplement et de désertification économique, fortement associé au vote d'extrême-droite dans les territoires ruraux.

2.2.6 Données territoriales complémentaires

- `SUPERF` — superficie du canton (densité de population)
- `NAIS1621`, `DECE1621` — naissances et décès entre 2016 et 2021 (dynamique naturelle de la population)
- `est_zone_urbaine` — variable binaire indiquant si le canton est classé en zone urbaine

2.3 Récapitulatif des variables et leur importance

Variable	Importance ML	Interprétation
<code>delta_Delinquance</code>	17.46%	Délinquance départementale (taux/1000 hab.)
<code>delta_P22_POP1564</code>	7.75%	Variation pop. active 15-64 ans
<code>delta_P16_POP</code>	6.21%	Variation population totale
<code>delta_P22_LOGVAC</code>	5.76%	Variation logements vacants
<code>delta_P22_LOG</code>	5.75%	Variation parc logements
Autres variables delta (23)	57.07%	Activité, emploi, entreprises...

TABLE 2.3 – Top 5 des variables par importance dans le modèle XGBoost

Au total, **28 variables delta** ont été utilisées comme features d'entrée du modèle, calculées à partir de **172 colonnes** dans le jeu de données final de **858 024 lignes**.

Chapitre 3

Architecture et pipeline de données

3.1 Vue d'ensemble de l'architecture

L'architecture du projet repose sur un pipeline ETL en **8 phases**, transformant des fichiers sources bruts (Excel, CSV) en un jeu de données analytique unifié stocké au format **Delta Lake** (Parquet Snappy), puis en prédictions JSON consommées par le dashboard web.




FIGURE 3.1 – Schéma global du flux de données

3.2 Pipeline ETL détaillé

3.2.1 Phase 1–2 : Extraction et fusion des sources

Les données brutes sont chargées depuis quatre sources distinctes :

- `data_election_2012.xlsx` et `data_election_2017.xlsx` — résultats électoraux au premier tour par canton (fichiers Excel issus de `data.gouv.fr`)
- Indicateurs INSEE 2016 et 2022 — données démographiques, emploi, logement, activité économique par commune (CODGEO)
- Statistiques de la délinquance par département (**taux pour 1 000 habitants**) — ministère de l’Intérieur, via `data.gouv.fr`
- Données établissements 2023 (INSEE) — nombre d’entreprises actives par secteur NAF

Ces sources sont fusionnées sur la clé composite `code_departement` + `Code du canton` + `Année`, produisant une table unique de **25 574 lignes** × **172 colonnes**.

3.2.2 Phase 3 : Normalisation des orientations politiques

Chaque candidat présent dans les données électorales est recodé en **orientation politique** via une table de correspondance fixe. Cette étape est indispensable pour construire la variable cible du modèle supervisé (voir Chapitre 5).

3.2.3 Phase 4 : Nettoyage des données

- Remplacement des valeurs manquantes par la **médiane** de la colonne correspondante
- Suppression des doublons
- Vérification de la cohérence des codes géographiques (CODGEO)

3.2.4 Phase 5 : Augmentation temporelle

Trois fenêtres temporelles sont créées afin d’augmenter la volumétrie du jeu d’entraînement :

Période	Données mobilisées
2012–2017	Élections 2012 + indicateurs 2016
2016–2020	Indicateurs 2016 + indicateurs 2020
2016–2020	Délinquance 2016 (sécurité départementale)

TABLE 3.1 – Fenêtres temporelles créées lors de l’augmentation

3.2.5 Phase 6 : Feature Engineering

- **Agrégations géographiques** : commune → canton → département → région
- **Intégration de la délinquance** : jointure du taux de délinquance départemental sur chaque canton, produisant la variable `delta_Delinquance` — qui s’avère être la variable la plus déterminante du modèle (cf. Chapitre 2). Cette donnée étant départementale, tous les cantons d’un même département partagent la même valeur (limite de granularité assumée)
- **Variable binaire** `est_zone_urbaine` : classification urbain/rural de chaque canton
- **Variables d’interaction** : `delta_col` × `est_zone_urbaine`

- **Perturbations gaussiennes** : bruit de $\pm 2\%$ appliqué sur les colonnes numériques pour améliorer la généralisation du modèle
- **Résultat** : **858 024 lignes** $\times$ **172 colonnes** (augmentation $\times 34$ par rapport aux données brutes)

3.2.6 Phase 7 : Normalisation

Un **MinMax Scaler** est appliqué sur les **125 colonnes numériques** (les colonnes binaires sont exclues), ramenant toutes les valeurs dans l'intervalle $[0, 1]$.

3.2.7 Phase 8 : Chargement (Load)

Les données transformées sont exportées dans deux formats :

Format	Taille	Lignes	Usage
CSV	2 215 MB	858 024	Entraînement ML (pandas)
Parquet	293 MB	858 024	Stockage optimisé
Delta Lake	29.4 MB	25 574	Versionnement (delta-rs)
JSON	~ 10 MB	127 260	Dashboard web

TABLE 3.2 – Formats d'export et leur usage

Le **Delta Lake** utilise le moteur `delta-rs:py-1.5.1` avec compression Snappy. Deux versions (v0 et v1) sont tracées dans le `_delta_log/`, garantissant la reproductibilité et la traçabilité des transformations.

3.3 Modèle Conceptuel de Données (MCD)

Le schéma conceptuel représente les entités logiques du projet et leurs relations. La base analytique finale est dénormalisée (approche *wide table*) pour optimiser les performances des algorithmes de machine learning, mais le MCD ci-dessous reflète le modèle logique des données sources.




FIGURE 3.2 – Modèle Conceptuel de Données

Les entités principales sont les suivantes :

REGION `id_region`, `nom_region`

DEPARTEMENT code_departement (PK), nom_departement, id_region (FK → REGION)

CANTON code_canton (PK), nom_canton, CODGEO, SUPERF, est_zone_urbaine, code_departement (FK → DEPARTEMENT)

ELECTION id_election (PK), code_canton (FK), Annee, Tour, Inscrits, Abstentions, Votants, Exprimes, vainqueur_nom, vainqueur_voix, orientation

INDICATEUR_SOCIOECO id_indicateur (PK), CODGEO (FK → CANTON), Annee, P22_POP, P16_POP, P22_EMPLT, P22_EMPLT_SAL, P22_ACT1564, P22_CHOM1564, P22_LOG, P22_LOGVAC, P22_MEN, MED21, ETTOT23

SECURITE id_securite (PK), code_departement (FK), Annee, Taux_Delinquance (taux de délinquance pour 1 000 habitants, à l'échelle départementale)

VARIATION_DELTA id_delta (PK), CODGEO (FK), Annee, delta_Delinquance, delta_P16_POP, delta_P22_POP1564, delta_P22_ACT1564, delta_P22_LOG, delta_P22_LOGVAC, etat_economique, orientation_predite

3.4 Nommage des tables et des champs

La convention de nommage adoptée dans ce projet suit les règles suivantes :

- **Codes INSEE** : préfixe P22_ pour les données 2022, P16_ pour 2016
- **Variables de variation** : préfixe delta_ suivi du code INSEE correspondant (ex. delta_Delinquance pour la variation du taux de délinquance)
- **Établissements par secteur** : préfixe ET suivi du code NAF et de l'année (ETTOT23, ETAZ23...)
- **Identifiants géographiques** : CODGEO (code commune INSEE), code_departement (2 chiffres)
- **Variables calculées** : snake_case explicite (etat_economique, orientation_predite, est_zone_urbaine)

3.5 Conformité RGPD et gouvernance des données

L'ensemble des données mobilisées dans ce projet sont **publiques et agrégées** à l'échelle territoriale (canton, département) : résultats électoraux, statistiques INSEE et taux de délinquance du ministère de l'Intérieur. Elles ne contiennent **aucune donnée à caractère personnel** — aucun individu n'est identifiable.

Le projet est donc **conforme au RGPD par construction** : il n'opère aucun traitement de données personnelles nécessitant une base légale, un consentement ou des mesures de sécurisation spécifiques. La traçabilité des sources (data.gouv.fr, INSEE, ministère de l'Intérieur) et le versionnement Delta Lake garantissent par ailleurs l'auditabilité complète du pipeline, de la donnée brute jusqu'à la prédiction.

Chapitre 4

Démarche et analyse exploratoire

4.1 Nettoyage des données

4.1.1 Traitement des valeurs manquantes

Après la fusion des sources hétérogènes (données électorales, INSEE, statistiques de délinquance), le jeu de données présentait des valeurs manquantes sur plusieurs colonnes socio-économiques. La stratégie de traitement adoptée est la suivante :

- **Colonnes numériques** : remplacement par la **médiane** de la colonne correspondante
 - méthode robuste aux valeurs extrêmes, préférable à la moyenne pour des distributions asymétriques
- **Colonnes textuelles** : remplacement par la valeur 'UNKNOWN' pour préserver l'intégrité du jeu de données
- **Valeurs infinies** : remplacées par `np.nan` avant imputation

	Département	Canton	Inscrits	Votants	Exprimés	Voix MACRON	Voix LE PEN	Voix FILLON
498	Charente	Angoulême-1	12295	8846	8633	2297	1291	1641
499	Charente	Angoulême-2	12737	9225	8996	2380	1438	1467
500	Charente	Angoulême-3	14409	10513	10294	2891	1514	1858
501	Charente	Boëme-Echelle	14236	11794	11470	2843	2736	1701
502	Charente	Boixe-et-Manslois	13256	10845	10499	2230	2827	1637
503	Charente	Charente-Bonnieure	12930	10139	9806	2208	2172	1448
504	Charente	Charente-Champagne	13209	10547	10252	2319	2481	2188
505	Charente	Charente-Nord	14240	11207	10820	2570	2408	1997
506	Charente	Charente-Sud	14908	11929	11561	2724	2695	2197
507	Charente	Charente-Vienne	13967	11262	10827	2548	2291	1604

FIGURE 4.1 – Données électorales brutes avant nettoyage : 1^{er} tour 2017 par canton, avec les voix réelles par candidat (nombres entiers, non normalisés).

4.1.2 Suppression des doublons

Une opération `drop_duplicates()` est appliquée sur la table fusionnée afin d'éliminer les enregistrements redondants issus des jointures entre sources.

4.1.3 Normalisation

Deux étapes de normalisation sont appliquées à des stades différents du pipeline :

1. **MinMax Scaler** (phase ETL) : appliqué sur les **125 colonnes numériques** (hors colonnes binaires), ramenant toutes les valeurs dans l'intervalle $[0, 1]$.
2. **Standard Scaler** (phase ML) : appliqué sur le jeu d'entraînement avant la modélisation, centrant les features à moyenne 0 et écart-type 1. Les paramètres du scaler sont appris uniquement sur le train set, puis appliqués au test set pour éviter toute fuite de données (*data leakage*).

4.1.4 Résultat après nettoyage

Indicateur	Valeur
Nombre de lignes finales	858 024
Nombre de colonnes	172
Valeurs manquantes	0
Doublons	0
Distribution Crise	13.4%
Distribution Déclin	14.2%
Distribution Stable	40.4%
Distribution Croissance	20.4%
Distribution Boom	11.5%

TABLE 4.1 – État du jeu de données après nettoyage complet

La variable cible comporte **5 classes** d'état socio-économique (Crise, Déclin, Stable, Croissance, Boom). La classe *Stable* étant majoritaire, un **échantillonnage stratifié** (`stratify=y`) est appliqué lors de la division train/test afin de préserver la distribution des classes dans les deux jeux et d'éviter tout biais lié au déséquilibre (*class imbalance*).

	Département	Canton	Délinquance	Chômage	Population	Vainqueur réel	Orientation réelle
1	Landes	Adour Armagnac	0.355	0.298	0.235	MACRON	Centre
3	Dordogne	Sud-Bergeracois	0.130	0.690	0.594	LE PEN	Extrême droite
5	Haute-Vienne	Limoges-5	0.293	0.551	0.600	MACRON	Centre
8	Charente	Cognac-2	0.445	0.481	0.692	MACRON	Centre
9	Charente	Jamac	0.445	0.360	0.435	MACRON	Centre
10	Corrèze	Ussel	0.156	0.724	0.417	MACRON	Centre
12	Dordogne	Vallée Dordogne	0.130	0.526	0.348	MACRON	Centre
18	Dordogne	Ribérac	0.130	0.582	0.469	LE PEN	Extrême droite
22	Gironde	Le Bouscat	1.000	0.482	0.569	MACRON	Centre
26	Charente	Boixe-et-Manslois	0.445	0.528	0.545	LE PEN	Extrême droite

FIGURE 4.2 – Extrait de la base finale d’entraînement après nettoyage et normalisation : variables d’entrée du modèle (en 0–1, dont la délinquance) et résultat réel utilisé uniquement pour la validation.

4.2 Analyse exploratoire

4.2.1 Visualisations descriptives

Plusieurs visualisations ont été produites pour explorer les données avant la phase de modélisation :

- **Graphiques d’importance des features** : diagramme en barres des variables les plus importantes selon le modèle XGBoost, largement dominé par la délinquance
- **Matrice de confusion** (5×5) : analyse des erreurs de classification entre les classes Crise, Déclin, Stable, Croissance et Boom
- **Courbes de validation croisée** : évolution de l’accuracy sur les 5 folds avec barres d’erreur (CV moyenne 76.59%)
- **Rapport de classification** : précision, rappel et F1-score par classe




FIGURE 4.3 – Importance des variables — modèle XGBoost (la délinquance en tête)

4.2.2 Corrélations entre indicateurs et résultats électoraux

L'analyse des importances de variables du modèle XGBoost révèle que la **délinquance est le prédicteur dominant** des tendances électorales en Nouvelle-Aquitaine, suivie des indicateurs démographiques et de logement.

Rang	Variable	Importance
1	delta_Delinquance	17.46%
2	delta_P22_POP1564	7.75%
3	delta_P16_POP	6.21%
4	delta_P22_LOGVAC	5.76%
5	delta_P22_LOG	5.75%
6	delta_P22_ACT1564	4.63%
7	delta_ETAZ23	3.16%
8	delta_NAISD24	3.14%
9	delta_P22_EMPLT_SAL	3.07%
10	delta_P22_CHOM1564	2.58%

TABLE 4.2 – Top 10 des variables par importance dans le modèle XGBoost

On notera que le chômage (delta_P22_CHOM1564) et l'emploi salarié (delta_P22_EMPLT_SAL) figurent bien dans le modèle, mais avec une importance plus faible que la délinquance, la démographie et le logement.

4.3 Réponse à la question jury : quelle donnée est la plus corrélée aux résultats électoraux ?

4.3.1 Résultat

La variable la plus corrélée aux résultats électoraux est `delta_Delinquance`, soit le **taux de délinquance départemental (pour 1 000 habitants)**, avec une importance de **17.46%** dans le modèle XGBoost — soit plus du double de la deuxième variable la plus déterminante.

4.3.2 Interprétation

Ce résultat s'explique par le lien fort entre insécurité perçue et comportement électoral :

- Les territoires à **taux de délinquance élevé** sont orientés par le modèle vers un état socio-économique **dégradé** et un **vote de rupture (Marine Le Pen, Extrême Droite)**
 - la sécurité étant un thème central des territoires en difficulté
- Les territoires à **faible délinquance**, plus souvent dynamiques et urbains, s'orientent vers un vote **Emmanuel Macron (Centre)**
- La classe **Stable** représente la majorité de la région (40.4% des observations) et vote également majoritairement **Macron**, ce que le modèle prédit correctement à l'échelle régionale (accuracy 76.67%)

Limite à signaler au jury. La délinquance étant disponible uniquement à l'échelle *départementale*, tous les cantons d'un même département partagent la même valeur. Cette granularité grossière explique certaines erreurs de prédiction cantonales (cf. Chapitre 6, cas de la Gironde) et constitue une piste d'amélioration assumée.

4.3.3 Confirmation par les variables complémentaires

Les variables suivantes du classement viennent renforcer cette lecture. La **variation de la population en âge de travailler** (`delta_P22_POP1564`, 7.75%) et la **variation de la population totale** (`delta_P16_POP`, 6.21%) mesurent l'érosion ou le renforcement du bassin de population — un signal directement ressenti par les électeurs.

La **variation du parc de logements vacants** (`delta_P22_LOGVAC`, 5.76%) confirme également ce diagnostic : un stock croissant de logements vacants est le signe d'un territoire en déclin, corrélé au vote protestataire. La combinaison *délinquance élevée + dépeuplement + logements vacants* dresse le portrait type d'un territoire fragilisé.

Chapitre 5

Modèles de Machine Learning

5.1 Apprentissage supervisé — définition

L'apprentissage supervisé est une branche du machine learning dans laquelle un algorithme apprend à associer des entrées (features) à des sorties (labels) à partir d'un jeu de données *étiqueté*, c'est-à-dire pour lequel la réponse correcte est déjà connue pour chaque exemple d'entraînement.

« *L'algorithme reçoit des paires (x_i, y_i) et cherche une fonction f telle que $f(x_i) \approx y_i$ pour minimiser une erreur de prédiction sur de nouvelles données jamais vues.* »

Dans notre contexte, les entrées sont les 28 colonnes `delta_*` (variations socio-économiques intercensitaires, **dont la délinquance**) et les sorties sont les cinq classes d'état socio-économique : **Crise**, **Déclin**, **Stable**, **Croissance**, **Boom**. Le modèle apprend, sur 80 % des données, quelles combinaisons de variations correspondent à chaque classe ; il est ensuite évalué sur les 20 % restants qu'il n'a jamais vus.

5.2 Stratégie d'évaluation

5.2.1 Découpage train / test

Le jeu de données final contient **858 024 lignes** après augmentation. La division est effectuée avec `train_test_split` de scikit-learn, paramètres `test_size=0.2`, `random_state=42` et `stratify=y` pour garantir que chaque classe est représentée proportionnellement dans les deux ensembles.

TABLE 5.1 – Répartition train / test (stratifiée)

Ensemble	Lignes	Part	Classe la plus fréquente
Entraînement	686 419	80,0 %	Stable : 40 %
Test	171 605	20,0 %	Stable : 40 %

La stratification est vérifiée : chaque classe conserve la même distribution que dans le jeu complet (Crise 13 %, Déclin 14 %, Stable 40 %, Croissance 21 %, Boom 12 %).

5.2.2 Validation croisée 5-fold stratifiée

Pour obtenir une estimation fiable de la généralisation, une `StratifiedKfold` à 5 plis est appliquée *sur l'ensemble d'entraînement*. Le jeu de test est conservé entièrement hors de cet entraînement croisé et sert uniquement à l'évaluation finale.

5.3 Algorithmes évalués

Cinq algorithmes de classification ont été identifiés et importés dans le pipeline Python :

- **XGBoost** (`xgboost.XGBClassifier`) — gradient boosting optimisé, arbres de décision en séquence ;
- **Random Forest** (`RandomForestClassifier`) — forêt d'arbres de décision indépendants, vote majoritaire ;
- **Gradient Boosting** (`HistGradientBoostingClassifier`) — boosting gradient histogramme de scikit-learn ;
- **Régression Logistique** (`LogisticRegression`) — modèle linéaire à base de probabilités ;
- **SVM Linéaire** (`SGDClassifier`, `loss="log_loss"`) — machine à vecteurs de support linéaire.

Les cinq modèles ont été comparés sur le jeu de test :

TABLE 5.2 – Comparaison des cinq modèles (jeu de test)

Modèle	Accuracy	Précision	Rappel	F1-Score
Régression Logistique	76,76 %	76,85 %	76,76 %	76,75 %
XGBoost	76,67 %	76,65 %	76,67 %	76,60 %
Gradient Boosting	75,48 %	75,37 %	75,48 %	75,11 %
Random Forest	72,57 %	73,19 %	72,57 %	71,22 %
SVM (Linéaire)	66,69 %	67,22 %	66,69 %	62,95 %

La Régression Logistique et XGBoost arrivent au coude-à-coude ($\approx 76,7\%$, écart de seulement 0,09 point). **XGBoost** a néanmoins été retenu comme modèle principal car il fournit une mesure d'**importance des variables** — indispensable pour répondre à la question du jury sur la donnée la plus déterminante (cf. Chapitre 4) — et capture les relations **non linéaires** entre indicateurs, contrairement au modèle linéaire.

5.4 Modèle sélectionné : XGBoost

5.4.1 Hyperparamètres

TABLE 5.3 – Hyperparamètres de l'`XGBClassifier` retenu

Paramètre	Valeur
<code>max_depth</code>	4
<code>n_estimators</code>	100
<code>learning_rate</code>	0,10
<code>eval_metric</code>	<code>mlogloss</code>
<code>n_jobs</code>	-1 (tous les cœurs)
<code>random_state</code>	42

5.4.2 Résultats de la validation croisée (5-fold)

TABLE 5.4 – Résultats XGBoost — Validation croisée 5-fold

Fold	Accuracy (CV)
1	76,47 %
2	76,63 %
3	76,57 %
4	76,58 %
5	76,71 %
Moyenne	76,59 %
Écart-type	$\pm 0,08$ %

La faible variance entre les folds ($\pm 0,08$ %) confirme que le modèle ne sur-apprend pas et se comporte de façon stable quelle que soit la partition des données.

5.4.3 Résultats sur l'ensemble de test

TABLE 5.5 – Métriques XGBoost sur le jeu de test (171 605 lignes)

Métrique	Accuracy	Précision	Rappel	F1-Score
Valeur	76,67 %	76,65 %	76,67 %	76,60 %

L'écart entre la performance CV (76,59 %) et la performance test (76,67 %) n'est que de **0,08** %, ce qui atteste de l'absence de sur-apprentissage.

5.4.4 Performance par classe

TABLE 5.6 – Rapport de classification par classe (jeu de test)

Classe	Précision	Rappel	F1-Score	Support
Crise	90,6 %	86,1 %	88,3 %	23 052
Déclin	67,1 %	62,4 %	64,7 %	24 438
Stable	79,5 %	84,0 %	81,7 %	69 265
Croissance	66,8 %	67,4 %	67,1 %	35 090
Boom	79,9 %	73,9 %	76,8 %	19 760
Moyenne pondérée	76,7 %	76,7 %	76,6 %	171 605

Les classes **Crise** ($F1 = 88,3$ %) et **Stable** ($F1 = 81,7$ %) sont les mieux discriminées : leurs signaux sont les plus contrastés (la Crise se distingue notamment par une délinquance élevée). À l'inverse, les classes intermédiaires **Déclin** ($F1 = 64,7$ %) et **Croissance** ($F1 = 67,1$ %) présentent les performances les plus faibles, car elles sont fréquemment confondues avec la classe **Stable** voisine, dont elles ne diffèrent que par de légères variations.

5.4.5 Matrice de confusion

La matrice de confusion 5×5 (générée dans le notebook d'entraînement) confirme cette lecture : l'essentiel des erreurs se concentre sur les frontières entre la classe **Stable** et ses voisines immédiates (**Déclin** et **Croissance**), tandis que les classes extrêmes (**Crise** et **Boom**) sont rarement confondues entre elles.




FIGURE 5.1 – Matrice de confusion — XGBoost (jeu de test, 5 classes)

5.5 Normalisation des données d'entrée

Avant l'entraînement, les 28 features `delta_*` sont normalisées avec un `StandardScaler` (centrage-réduction : moyenne = 0, écart-type = 1). Le scaler est **ajusté uniquement sur le jeu d'entraînement** (`fit_transform`) puis appliqué sans ré-ajustement sur le jeu de test (`transform`), ce qui évite toute fuite de données (*data leakage*).

- `X_train` après normalisation : moyenne = 0,0000, écart-type = 1,0000
- `X_test` après normalisation : moyenne = 0,0003, écart-type = 1,0020

L'écart quasi nul sur le jeu de test confirme la cohérence des distributions entre les deux ensembles.

Chapitre 6

Résultats

6.1 Choix du modèle final : XGBoost

Parmi les cinq algorithmes évalués lors de la phase d’expérimentation (XGBoost, Random Forest, Gradient Boosting, Régression Logistique, SVM), le modèle **XGBoost** a été retenu comme modèle de production pour trois raisons cumulées.

1. Performances de premier rang. XGBoost atteint **76,67 %** d’accuracy sur le jeu de test et **76,59 %** en validation croisée 5-fold, avec un écart de seulement 0,08 % entre les deux mesures — signe que le modèle généralise sans sur-apprentissage. Il se situe au coude-à-coude avec la Régression Logistique (76,76 %), dont il ne se distingue que de 0,09 point.

2. Stabilité inter-folds. L’écart-type des scores de cross-validation est de $\pm 0,08$ % (intervalle : [76,47 %; 76,71 %]), ce qui signifie que les performances sont reproductibles indépendamment de la partition des données.

3. Interprétabilité native. XGBoost expose des *feature importances* calculées via le gain des arbres. Cette propriété est essentielle pour Electio-Analytics, qui doit pouvoir expliquer à ses clients *pourquoi* un canton est classé dans tel ou tel état — c’est elle qui a permis d’identifier la **délinquance** comme variable la plus déterminante (cf. Chapitre 4).

6.2 Accuracy — définition et interprétation

6.2.1 Définition formelle

L’**accuracy** (degré de précision) est la métrique la plus directe pour évaluer un classificateur. Elle mesure la proportion d’exemples correctement classés sur l’ensemble de test :

$$\text{Accuracy} = \frac{\text{Nombre de prédictions correctes}}{\text{Nombre total de prédictions}} = \frac{TP_1 + TP_2 + \dots + TP_k}{N} \quad (6.1)$$

où TP_k est le nombre de vrais positifs pour la classe k et N est le nombre total d’observations du jeu de test.

6.2.2 Application numérique

Sur notre jeu de test ($N = 171\,605$ observations), la somme des éléments diagonaux de la matrice de confusion (les prédictions correctes des cinq classes) vaut environ 131 580 :

$$\text{Accuracy} = \frac{\sum_k TP_k}{N} = \frac{131\,580}{171\,605} \approx \mathbf{76,67\%} \quad (6.2)$$

Ces éléments diagonaux correspondent aux observations correctement classées de chaque classe (Crise, Déclin, Stable, Croissance, Boom), reportées dans le rapport de classification (chapitre 5, tableau 5.6).

6.2.3 Limites de l’accuracy

L’accuracy seule peut être trompeuse lorsque les classes sont déséquilibrées. Dans notre cas, la distribution est **modérément déséquilibrée**, la classe *Stable* étant majoritaire (40 %). C’est pourquoi nous reportons également la **précision pondérée** (76,65 %) et le **F1-Score pondéré** (76,60 %), tous deux cohérents avec l’accuracy, ainsi que les métriques détaillées **par classe** (chapitre 5) qui révèlent les écarts de performance entre classes extrêmes et classes intermédiaires.

6.3 Résultats sur la Nouvelle-Aquitaine

6.3.1 Niveau régional

Le modèle XGBoost agrège les 28 features `delta_*` à l’échelle de la région entière (moyenne des 858 024 observations) et produit la prédiction suivante :

TABLE 6.1 – Prédiction régionale — Nouvelle-Aquitaine

Paramètre	Valeur
État économique prédit	Stable
Orientation politique	Centre
Candidat prédit	MACRON
Probabilité MACRON	93,16 %
Probabilité opposition	6,84 %
Accuracy du modèle	76,67 %
Résultat réel 2022	MACRON
Prédiction correcte	Oui

6.3.2 Niveau départemental

Le modèle est ensuite appliqué aux 12 départements de la région. Sur les 12 départements, **10 sont correctement prédits** (10 victoires MACRON). Deux écarts subsistent, de sens opposé : la **Gironde** (prédite LE PEN, réellement MACRON) et le **Lot-et-Garonne** (prédit MACRON, réellement LE PEN).

TABLE 6.2 – Prédiction par département

Département	Prédit	Réel 2022	Correct
Charente	MACRON	MACRON	✓
Charente-Maritime	MACRON	MACRON	✓
Corrèze	MACRON	MACRON	✓
Creuse	MACRON	MACRON	✓
Dordogne	MACRON	MACRON	✓
Gironde	LE PEN	MACRON	×
Landes	MACRON	MACRON	✓
Lot-et-Garonne	MACRON	LE PEN	×
Pyrénées-Atlantiques	MACRON	MACRON	✓
Deux-Sèvres	MACRON	MACRON	✓
Vienne	MACRON	MACRON	✓
Haute-Vienne	MACRON	MACRON	✓
Total			10/12 (83,3 %)

Analyse des deux erreurs. Ces deux écarts illustrent la même limite : une donnée de sécurité disponible uniquement à l'échelle **départementale**.

- **Gironde** — prédit LE PEN à tort. La Gironde présente le **taux de délinquance le plus élevé de la région** (porté par l'agglomération bordelaise), valeur appliquée uniformément à tous ses cantons. La délinquance étant la variable la plus déterminante du modèle (17,46 %), ce taux élevé fait basculer le département vers un état de crise et un vote de rupture (probabilité LE PEN : 91,5 %), malgré son dynamisme métropolitain réel.
- **Lot-et-Garonne** — prédit MACRON à tort. C'est le seul département réellement passé à LE PEN en 2022. Son taux de délinquance intermédiaire (0,43 normalisé) ne suffit pas à ce que le modèle capture ce basculement structurel.

Ces erreurs de sens opposé montrent que la granularité départementale de la délinquance **surpondère** les départements urbains à forte délinquance et **sous-estime** les ruptures rurales — une piste d'amélioration assumée (passer à une délinquance à la maille cantonale).

6.4 Prédiction temporelles par scénario économique

6.4.1 Principe de projection

L'état économique courant (calculé sur les données 2022) est **Stable**. Le modèle projette les tendances à **+1 an**, **+2 ans** et **+3 ans** en simulant l'évolution du score économique composite selon cinq scénarios définis dans le pipeline (`src/lib/predictions.ts`) :

TABLE 6.3 – Seuils économiques et orientations politiques associées

Scénario	$\Delta_{\text{éco}}$	Bloc politique	Candidat type
Boom	$> +5 \%$	Droite libérale	Pécresse / LR
Croissance	$+1 \%$ à $+5 \%$	Centre	Macron (Renaissance)
Stable	-1% à $+1 \%$	Centre	Macron (Renaissance)
Déclin	-1% à -5%	Gauche sociale	Mélenchon / LFI
Crise	$< -5 \%$	Extrême droite	Le Pen (RN)


6.4.2 Projections à 1, 2 et 3 ans

La Nouvelle-Aquitaine étant en état **Stable** en 2022 (score composite $\approx 6,99$), trois trajectoires sont simulées selon l'évolution des indicateurs `delta_*` :

TABLE 6.4 – Prédictions électorales par horizon temporel et scénario

Horizon	Scénario optimiste	Scénario de référence	Scénario pessimiste
+1 an	Croissance modérée ($\Delta > +1 \%$) Centre — Macron	Stable ($\Delta \approx 0 \%$) Centre — Macron	Déclin naissant ($\Delta < -1 \%$) Gauche — Mélenchon
+2 ans	Boom ($\Delta > +5 \%$) Droite — Pécresse/LR	Stable ($\Delta \approx 0 \%$) Centre — Macron	Déclin structurel ($\Delta \leq -3 \%$) Gauche — LFI/écologistes
+3 ans	Boom ($\Delta > +5 \%$) Droite — Pécresse/LR	Croissance ($\Delta \approx +2 \%$) Centre — Macron	Crise ($\Delta < -5 \%$) Extrême droite — Le Pen

1 - Indice économique régional projeté (0-10) — espérance du modèle



2 - Conséquence politique — composition du vote prédit (%)

● Centre (Macron) ● Droite (Péresse) ● Gauche (Mélenchon) ● RN (Le Pen)




FIGURE 6.1 – Projections temporelles à +1, +2 et +3 ans : indice économique régional projeté (haut) et composition du vote prédit selon les scénarios optimiste / neutre / pessimiste (bas).

6.4.3 Signaux économiques par scénario

Les basculements de scénario sont détectés à partir des variations des indicateurs clés identifiés par les feature importances du modèle :

- **Scénario optimiste** : baisse du taux de délinquance (`delta_Delinquance`) + hausse de `delta_P16_POP` (croissance démographique) + recul du chômage → bascule vers Centre puis Droite libérale.
- **Scénario de référence** : tous les indicateurs restent dans l'intervalle $[-1\%; +1\%]$ → le Centre se maintient avec une accuracy modèle de **76,67 %**.
- **Scénario pessimiste** : hausse du taux de délinquance (`delta_Delinquance`, variable n°1 du modèle) + décroissance de `delta_P22_POP1564` (perte de population active) + hausse des logements vacants (`delta_P22_LOGVAC`) → bascule progressive vers la Gauche puis, en cas de crise profonde, vers l'Extrême droite (cf. Lot-et-Garonne, seul département réellement en rupture en 2022).

6.4.4 Précision attendue des projections

La précision décroît naturellement avec l'horizon temporel, car les indicateurs socio-économiques utilisés comme features sont eux-mêmes des estimations :

TABLE 6.5 – Précision estimée des projections par horizon

Horizon	Précision estimée	Source d’incertitude principale
+1 an	$\approx 80 \%$	Données INSEE quasi disponibles
+2 ans	$\approx 70 \%$	Estimation partielle des indicateurs
+3 ans	$\approx 60 \%$	Modèles macro-économiques tiers nécessaires

Ces estimations sont cohérentes avec la littérature académique sur les modèles de prédiction électorale à court terme : une précision de $\pm 10 \%$ par année d’horizon supplémentaire est considérée comme standard pour un POC de première génération.

Chapitre 7

Visualisations et interface utilisateur

Le dashboard React déployé dans le cadre de ce POC comporte deux pages principales accessibles via TanStack Router :

- **Page principale** (/) — tableau de bord de prédictions avec filtres géographiques et sélecteur de modèle ;
- **Page visualisation** (/visualisation) — analyses graphiques approfondies : matrice de corrélation, comparaison de modèles et courbes d'apprentissage.

7.1 Page principale — tableau de bord de prédictions

7.1.1 Navigation et filtres

La barre de navigation fixe (*sticky top*) affiche en permanence le modèle actif et son accuracy. Deux niveaux de filtres sont proposés :

1. **Sélecteur de modèle** : cinq algorithmes disponibles — XGBoost, Random Forest, Gradient Boosting, Logistic Regression, SVM (Linear). Chaque sélection charge dynamiquement le fichier `predictions_<modèle>.json` via TanStack Query.
2. **Filtres géographiques en cascade** : Région (fixe : Nouvelle-Aquitaine) → Département → Canton. La sélection d'un département met à jour automatiquement la liste des cantons et toutes les visualisations associées.




FIGURE 7.1 – Barre de filtres — sélecteur de modèle et filtre géographique

7.1.2 Cartes KPI

Trois cartes de métriques clés (KpiCard) sont affichées sous les filtres, avec animation d’entrée Framer Motion :

TABLE 7.1 – Cartes KPI du tableau de bord

Carte	Valeur affichée	Sous-titre
Vainqueur prédit	MACRON	Réel : MACRON
État économique	STABLE	Score : 6,99
Accuracy modèle	76,7 %	Entraînement sur variables socio-éco




FIGURE 7.2 – Cartes KPI — vainqueur prédit, état économique, accuracy

7.1.3 Spectre politique dynamique

Le composant `PoliticalSpectrum` est la pièce centrale de la page. Il traduit l’état économique calculé pour l’entité sélectionnée en position sur l’échiquier politique.

- Une **barre de dégradé** représente le spectre de gauche à droite (Extrême Gauche → Gauche → Centre → Droite → Extrême Droite).
- Un **marqueur animé** (spring Framer Motion, raideur 180, amortissement 22) se déplace sur la barre en fonction du scénario économique détecté.

- Cinq **tuiles de scénarios** affichent le $\Delta_{\text{éco}}$ et le label (Boom / Croissance / Stable / Déclin / Crise). La tuile active est mise en surbrillance ; les autres sont grisées.
- Un **panneau résultat** détaille le scénario, le bloc politique gagnant, le candidat probable et la justification économique.
- Un **panneau signaux** liste les indicateurs clés avec leur tendance ($\nearrow$ hausse, $\searrow$ baisse, $\rightarrow$ stable).

Pour la Nouvelle-Aquitaine en état **Stable** : le marqueur se positionne au **Centre** (position 50/100), le bloc prédit est *Centre — Macron (Renaissance)* avec la justification : « *L'absence de choc favorise la continuité institutionnelle.* »




FIGURE 7.3 – Spectre politique — état économique Stable, marqueur Centre

7.1.4 Tableau de prédictions

Le composant `PredictionTable` affiche les prédictions par niveau géographique (Départements, Cantons, ou Canton sélectionné) dans un tableau interactif animé. Chaque ligne contient :

- **Entité** : nom du département ou canton ;
- **Bord & Gagnant** : étiquette colorée avec code couleur politique (bleu Centre pour MACRON, rouge/noir pour LE PEN) ;
- **État économique** : label en majuscules (STABLE, BOOM. . .) ;
- **Réel 2022** : résultat officiel, même format coloré ;
- **Probabilités** : barre bicolore montrant les probabilités MACRON (bleu) et opposition (rouge) côte à côte, avec valeurs exactes en pourcentage ;
- **Correcte** : icône verte ($\checkmark$) ou rouge ($\times$) selon concordance prédit / réel.

ENTITÉ	BORD & GAGNANT	ÉTAT ÉCONOMIQUE	RÉEL	PROBABILITÉS	✓
CHARENTE	CENTRE ● MACRON	STABLE	CENTRE ● MACRON	M 86.5% Opp. 13.5%	✓
CHARENTE MARITIME	CENTRE ● MACRON	STABLE	CENTRE ● MACRON	M 87.7% Opp. 12.3%	✓
CORREZE	CENTRE ● MACRON	STABLE	CENTRE ● MACRON	M 96.4% Opp. 3.6%	✓
CREUSE	CENTRE ● MACRON	STABLE	CENTRE ● MACRON	M 91.4% Opp. 8.6%	✓
DEUX SEVRES	CENTRE ● MACRON	STABLE	CENTRE ● MACRON	M 87.7% Opp. 12.3%	✓
DORDOGNE	CENTRE ● MACRON	STABLE	CENTRE ● MACRON	M 95.5% Opp. 4.5%	✓
GIRONDE	EXTRÊME DROITE ● LE PEN	CRISE	CENTRE ● MACRON	M 1.9% Opp. 98.1%	✗
HAUTE VIENNE	CENTRE ● MACRON	STABLE	CENTRE ● MACRON	M 96.7% Opp. 3.3%	✓
LANDES	CENTRE ● MACRON	STABLE	CENTRE ● MACRON	M 92.7% Opp. 7.3%	✓
LOT ET GARONNE	CENTRE ● MACRON	STABLE	EXTRÊME DROITE ● LE PEN	M 92.9% Opp. 7.1%	✗
PYRENEES ATLANTIQUES	CENTRE ● MACRON	STABLE	CENTRE ● MACRON	M 96.4% Opp. 3.6%	✓
VIENNE	CENTRE ● MACRON	STABLE	CENTRE ● MACRON	M 93.4% Opp. 6.6%	✓

FIGURE 7.4 – Tableau de prédictions — niveau Départements

7.1.5 Graphiques en anneau (donuts)

Deux graphiques PieChart Recharts en mode *donut* (rayon intérieur 56, rayon extérieur 84) s'affichent côte à côte lorsque la vue est au niveau régional :

- **Réel · Départements** : 11 MACRON / 1 LE PEN (le LE PEN réel étant le Lot-et-Garonne) ;
- **Prédit · Départements** : 11 MACRON / 1 LE PEN (le LE PEN prédit étant la Gironde).

Les deux donuts affichent le même décompte (11/1), mais le département classé LE PEN **diffère** : le modèle le place en Gironde (à tort), tandis que la réalité 2022 le situe en Lot-et-Garonne. La valeur centrale de chaque donut affiche le décompte du parti dominant.



FIGURE 7.5 – Donuts — répartition réelle (gauche) vs prédite (droite)

7.2 Page visualisation — analyses graphiques

7.2.1 Carte géographique de la Nouvelle-Aquitaine

Une carte choroplèthe des 12 départements colore chaque territoire selon la **probabilité de victoire de MACRON** prédite par le modèle (du bleu clair au bleu foncé). La Gironde apparaît en bleu clair, traduisant la faible probabilité MACRON qui découle de sa prédiction erronée (cf. Chapitre 6).




FIGURE 7.6 – Carte choroplèthe des 12 départements — probabilité MACRON prédite

7.2.2 Matrice de corrélation interactive

Une heatmap 8×8 visualise les corrélations de Pearson réelles entre sept indicateurs socio-économiques (Délinquance, Chômage, Emploi, Activité, Population, Logement, Entreprises) et le **Score** économique du modèle.

- Chaque cellule est colorée selon une rampe bleu $\rightarrow$ blanc $\rightarrow$ rouge ($-1,0$ à $+1,0$).
- Le survol (*hover*) scale la cellule à $\times 1,15$ et affiche la valeur exacte en surimpression.
- **Corrélations notables** (colonne Score économique) : **Délinquance** = $-0,70$ (corrélations négative la plus forte — confirme la délinquance comme premier facteur) ; **Population** = $+0,40$; **Logement** = $+0,26$; **Activité** = $+0,24$.
- Les indicateurs sont en revanche **quasi décorrélés entre eux** (valeurs proches de 0), ce qui indique qu'ils apportent chacun une information distincte au modèle.




FIGURE 7.7 – Matrice de corrélation interactive — 8 variables

7.2.3 Comparaison inter-modèles — BarChart et RadarChart

Deux graphiques côte à côte comparent les 5 modèles selon quatre métriques sélectionnables via onglets (Accuracy / Precision / Recall / F1-Score) :

TABLE 7.2 – Comparaison des 5 modèles — page Visualisation

Modèle	Accuracy	Précision	Rappel	F1
Logistic Reg.	76,76 %	76,85 %	76,76 %	76,75 %
XGBoost	76,67 %	76,65 %	76,67 %	76,60 %
Grad. Boost.	75,48 %	75,37 %	75,48 %	75,11 %
Random Forest	72,57 %	73,19 %	72,57 %	71,22 %
SVM (Linear)	66,69 %	67,22 %	66,69 %	62,95 %

Le **RadarChart** (Recharts RadarChart) superpose les courbes des cinq modèles sur les quatre axes métriques, offrant une lecture synthétique des profils de performance.




FIGURE 7.8 – Gauche : BarChart comparatif (Accuracy). Droite : Radar multi-métriques.

7.2.4 Courbes d'apprentissage

La section *Courbes d'Apprentissage* affiche l'évolution **réelle** du modèle **XGBoost** sur ses **100 itérations de boosting** (équivalent des epochs). Deux LineChart Recharts sont présentés en regard :

- **Courbes de Précision** : accuracy d'entraînement (bleu) et de validation (orange) en fonction de l'itération ;
- **Courbes de Perte** : log-loss d'entraînement et de validation, mêmes codes couleur.

À la 100^e itération, la courbe d'entraînement atteint **82,3 %** et la validation **75,8 %**, soit un écart d'apprentissage classique d'environ **6,5 points**. Cet écart, modéré et stable, confirme l'absence de sur-apprentissage excessif : le modèle progresse sur l'entraînement tout en généralisant correctement.




FIGURE 7.9 – Courbes d'apprentissage — XGBoost (accuracy et perte sur 100 itérations)

7.3 Stack technique de la couche visualisation

TABLE 7.3 – Technologies utilisées pour les visualisations

Librairie / Outil	Usage
Recharts 2.x	PieChart, BarChart, RadarChart, LineChart
Framer Motion 11	Animations d'entrée, marqueur spectre politique
TanStack Query 5	Chargement asynchrone de <code>predictions.json</code>
TanStack Router 1	Routage / et /visualisation
Tailwind CSS 4	Mise en page responsive, dark/light mode
Lucide React	Icônes (Activity, Brain, BarChart3...)
Shadcn/ui	Composants UI (cards, selects, buttons)

Conclusion et recommandations

Bilan du POC

Ce projet de fin d'études a permis de concevoir et de livrer un POC complet de prédiction électorale par indicateurs socio-économiques pour la société Electio-Analytics. L'ensemble de la chaîne de valeur Big Data a été implémentée, de l'ingestion des données brutes jusqu'à l'interface de restitution.

Pipeline de données. Un pipeline ETL en 8 phases a été développé en Python sur les données de la Nouvelle-Aquitaine (2012–2022). Après nettoyage, ingénierie de 28 variables `delta_*` (dont la délinquance) et augmentation des données ($\times 34$), le jeu final contient **858 024 lignes**, stockées au format Parquet Snappy (293 MB) ainsi qu'en Delta Lake versionné (29,4 MB compressés contre 2 215 MB en CSV brut).

Modèle prédictif. Le classificateur XGBoost retenu atteint **76,67 %** d'accuracy sur le jeu de test et **76,59 %** en validation croisée 5-fold ($\pm 0,08$ %), sans sur-apprentissage détectable (écart CV / test : 0,08 %). Appliqué aux 12 départements de la région, il prédit correctement **10/12 résultats** électoraux 2022 (83,3 %).

Interface utilisateur. Un tableau de bord React 19 (TanStack Router + TanStack Query + Recharts + Framer Motion) expose les prédictions à trois niveaux géographiques (région, département, canton), un spectre politique dynamique et une page de visualisation dédiée (heatmap de corrélations, comparaison inter-modèles, courbes d'apprentissage).

Réponse au besoin client. Le POC démontre la faisabilité technique de l'approche : des données publiques librement accessibles (data.gouv.fr, INSEE, statistiques de délinquance du ministère de l'Intérieur), traitées sans infrastructure coûteuse, permettent de prédire les tendances électorales avec une précision opérationnelle de l'ordre de **77 %** à l'échelle départementale. L'analyse a par ailleurs identifié la **délinquance** comme la variable la plus déterminante du modèle (importance 17,46 %), répondant directement à la question posée par le client.

Limites identifiées

Couverture géographique restreinte. Le modèle a été entraîné et évalué uniquement sur la Nouvelle-Aquitaine. Sa généralisation à d'autres régions (Île-de-France, Grand Est, etc.) n'a pas été validée et constitue la première limite du POC.

Fenêtre temporelle figée. Les features `delta_*` sont calculées sur la variation 2012–2017. Les dynamiques socio-économiques postérieures (crise COVID-19 2020–2021, inflation 2022–2023) ne sont pas capturées par le modèle actuel.

Classes intermédiaires moins discriminées. Les classes **Déclin** ($F1 = 64,7\%$) et **Croissance** ($F1 = 67,1\%$) présentent les F1-Scores les plus faibles : situées entre la classe majoritaire *Stable* et les classes extrêmes, elles sont fréquemment confondues avec leurs voisines, dont elles ne diffèrent que par de légères variations. À l'inverse, les classes extrêmes **Crise** ($88,3\%$) et **Stable** ($81,7\%$) sont bien identifiées.

Deux départements mal prédits. La **Gironde** (prédite LE PEN, réellement MACRON) et le **Lot-et-Garonne** (prédit MACRON, réellement LE PEN) sont les deux erreurs du modèle. Elles découlent de la même cause : la délinquance, variable la plus déterminante, n'est disponible qu'à l'échelle départementale. Le taux élevé de la Gironde (porté par l'agglomération bordelaise) fait basculer le département vers un vote de rupture à tort, tandis que le taux intermédiaire du Lot-et-Garonne ne suffit pas à capturer son basculement réel.

Prédictions temporelles par scénarios. Les projections à +1, +2 et +3 ans reposent sur des scénarios économiques définis à dire d'experts (`ECO_SCENARIOS` dans `predictions.ts`), et non sur une modélisation prévisionnelle des indicateurs INSEE. Leur précision diminue avec l'horizon temporel ($\approx 80\%$ à +1 an, $\approx 60\%$ à +3 ans).

Données de délinquance départementales. Bien qu'étant la variable la plus déterminante du modèle, la délinquance n'est disponible qu'à l'échelle **départementale** : tous les cantons d'un même département partagent la même valeur. Cette granularité grossière est la cause directe de l'erreur sur la Gironde et limite la finesse des prédictions cantonales.

Recommandations pour le passage en production

1 — Extension géographique. Répliquer le pipeline ETL sur les 12 régions métropolitaines pour obtenir un modèle national. La structure `delta_*` est déjà généralisable ; seule la collecte des données brutes régionales est à industrialiser.

2 — Mise à jour des données en continu. Remplacer les fichiers CSV statiques par des appels à l'API open data de l'INSEE et de `data.gouv.fr` (flux JSON/CSV mis à jour annuellement). Le Delta Lake en place permet la mise à jour incrémentale sans recalcul complet.

3 — Enrichissement des features. Intégrer des indicateurs post-2017 : taux d'inflation locale, prix de l'immobilier, résultats des élections intermédiaires (municipales, législatives) comme variables de signal précoce.

4 — API backend et découplage. Remplacer le fichier `predictions.json` statique par une API REST (FastAPI ou Flask) exposant les prédictions à la demande, avec mise en cache Redis. Cela permettrait un filtrage dynamique côté serveur et des prédictions en temps réel lors d'une soirée électorale.

5 — Amélioration des classes intermédiaires. Expérimenter une approche de *cost-sensitive learning* (pondération des classes) ou un post-traitement par seuil de décision pour améliorer les performances sur les classes **Déclin** et **Croissance** sans dégrader les classes extrêmes.

6 — Granularité communale et délinquance cantonale. Le modèle actuel est exploitable jusqu’au niveau canton. Un entraînement à l’échelon commune (données INSEE FILOSOFI) et surtout une **délinquance à la maille cantonale** (plutôt que départementale) corrigeraient l’erreur observée sur la Gironde et apporterait une précision accrue, donc une valeur commerciale supérieure pour Electio-Analytics.

7 — Validation prospective. Lors de la prochaine échéance électorale (élections législatives ou présidentielle 2027), confronter les prédictions du modèle aux résultats réels pour mesurer la dérive du modèle (*model drift*) et déclencher un réentraînement si l’accuracy descend sous un seuil défini (par exemple 72%).

En conclusion, ce POC démontre qu’un pipeline Big Data de taille raisonnable — fondé exclusivement sur des données publiques — peut produire des prédictions électorales fiables à l’échelle régionale. Les **76,7 %** d’accuracy obtenus constituent un résultat solide et *réaliste* pour un premier prototype, et l’identification de la délinquance comme premier facteur prédictif, tout comme l’analyse honnête des deux erreurs départementales, témoignent d’une maîtrise du modèle. Les recommandations formulées ci-dessus dessinent une feuille de route claire pour industrialiser la solution en production au service d’Electio-Analytics.

Annexe A

Schéma du jeu de données nettoyé

Structure du fichier `data_nouvelle_aquitaine_final.csv`

Le fichier final contient **172 colonnes** réparties en quatre blocs.

Bloc 1 — Identifiants géographiques et électoraux

TABLE A.1 – Colonnes identifiants (sélection)

Colonne	Type	Description
<code>code_departement</code>	str	Code INSEE du département (ex. 16)
Libellé du département	str	Nom du département
Code du canton	str	Code INSEE du canton
Libellé du canton	str	Nom du canton
<code>CODGEO</code>	str	Clé géographique commune (5 chiffres)
<code>vainqueur_nom</code>	str	Nom du candidat vainqueur (Tour 1)
<code>orientation</code>	str	Bloc politique : Centre / exD / exG / G / D
Année	int	Année de l'élection (2012 ou 2017)

Bloc 2 — Indicateurs INSEE bruts et sécurité

TABLE A.2 – Indicateurs socio-économiques bruts (sélection)

Colonne	Type	Description
<code>P22_POP</code>	float	Population totale 2022
<code>P16_POP</code>	float	Population totale 2016
<code>P22_POP1564</code>	float	Population active (15–64 ans) 2022
<code>P22_ACT1564</code>	float	Actifs 15–64 ans 2022
<code>P22_EMPLT</code>	float	Emplois totaux 2022
<code>P22_EMPLT_SAL</code>	float	Emplois salariés 2022
<code>P22_LOG</code>	float	Logements totaux 2022
<code>P22_LOGVAC</code>	float	Logements vacants 2022
<code>MED21</code>	float	Revenu médian 2021
<code>ETT0T23</code>	int	Établissements totaux 2023
<code>Taux_Delinquance</code>	float	Taux de délinquance départemental (pour 1 000 hab.)

Bloc 3 — Variables delta_* (features ML)

Les 28 variables `delta_*` calculées comme $\Delta = (V_{\text{récent}} - V_{\text{ancien}})/(V_{\text{ancien}} + \varepsilon)$ (la délinquance étant intégrée sous forme normalisée par département) :

TABLE A.3 – Variables delta — top 10 par importance

Colonne	Importance XGB	Interprétation
<code>delta_Delinquance</code>	17,46 %	Taux de délinquance départemental
<code>delta_P22_POP1564</code>	7,75 %	Évolution pop. active 15–64 ans
<code>delta_P16_POP</code>	6,21 %	Évolution population 2016
<code>delta_P22_LOGVAC</code>	5,76 %	Évolution logements vacants
<code>delta_P22_LOG</code>	5,75 %	Évolution parc immobilier
<code>delta_P22_ACT1564</code>	4,63 %	Évolution actifs 15–64 ans
<code>delta_ETAZ23</code>	3,16 %	Évolution établissements agricoles
<code>delta_NAISD24</code>	3,14 %	Évolution des naissances
<code>delta_P22_EMPLT_SAL</code>	3,07 %	Évolution emplois salariés
<code>delta_P22_CHOM1564</code>	2,58 %	Évolution chômage 15–64 ans

Bloc 4 — Métadonnées d’augmentation

TABLE A.4 – Colonnes de contrôle de l’augmentation

Colonne	Type	Valeurs
<code>periode</code>	str	<code>electorales_2012_2017 /</code> <code>indicateurs_2016_2020 /</code> <code>securite_2016_2020</code>
<code>annee</code>	float	2012 à 2021 (normalisé 0–1)
<code>nb_annees_depuis_debut</code>	int	0 à 5
<code>est_zone_urbaine</code>	int	0 / 1
<code>est_perturbation</code>	int	0 (original) / 1 (bruit $\pm 1\%$)

Annexe B

Extraits de code commentés

Extrait 1 — Calcul des variables delta_* (Phase 2 ETL)

Listing B.1 – Calcul des variations intercensitaires — Notebook ETL Phase 2

```
def calculate_delta(df_old, df_recent, join_col='CODGEO'):
    """
    Calcule (V_recent - V_old) / (V_old + eps) pour chaque variable
    numerique commune aux deux datasets.
    Le epsilon (1e-9) evite la division par zero.
    """
    merged = pd.merge(
        df_old[[join_col] + common_nums],
        df_recent[[join_col] + common_nums],
        on=join_col, suffixes=('_old', '_recent'), how='inner'
    )
    for col in common_nums:
        merged[f'delta_{col}'] = (
            (merged[f'{col}_recent'] - merged[f'{col}_old'])
            / (merged[f'{col}_old'] + 1e-9)
        )
        # Remplacement des infinis et NaN par 0
        merged[f'delta_{col}'] = (
            merged[f'delta_{col}']
            .replace([np.inf, -np.inf], 0)
            .fillna(0)
        )
    return merged[[join_col] + [f'delta_{c}' for c in common_nums]]
```

Extrait 2 — Intégration de la délinquance (Phase 6 ETL)

Listing B.2 – Jointure du taux de délinquance départemental — Phase 6

```
# Lecture du taux de delinquance par departement (pour 1000 hab.)
deli = pd.read_csv(DELI_PATH, encoding="utf-8-sig")
deli["key"] = deli["Departement"].map(sans_accents)

# Normalisation min-max du taux (0 = plus faible, 1 = plus eleve)
```



```

tmin, tmax = deli["Taux_Delinquance"].min(), deli["Taux_Delinquance"].max()
deli["norm"] = (deli["Taux_Delinquance"] - tmin) / (tmax - tmin)

# Jointure sur le departement -> chaque canton recoit la valeur de son
# departement
fin["delta_Delinquance"] = (
    fin["Libelle_du_departement"].map(sans_accents)
    .map(dict(zip(deli["key"], deli["norm"])))
)
# La Gironde obtient la valeur maximale (1.0), la Creuse la minimale
# (0.0)

```

Extrait 3 — Nettoyage des valeurs manquantes (Phase 5 ETL)

Listing B.3 – Gestion des valeurs manquantes et doublons — Phase 5

```

# Remplacement des valeurs manquantes numeriques par la mediane
for col in numeric_cols:
    if data_fusionnee[col].isnull().any():
        median_val = data_fusionnee[col].median()
        data_fusionnee[col].fillna(median_val, inplace=True)

# Valeurs texte manquantes -> 'UNKNOWN'
for col in text_cols:
    data_fusionnee[col].fillna('UNKNOWN', inplace=True)

# Suppression des doublons
initial_rows = len(data_fusionnee)
data_fusionnee = data_fusionnee.drop_duplicates()
# Resultat : 0 doublon supprime (dataset propre)

```

Extrait 4 — Augmentation des données (Phase 6 ETL)

Listing B.4 – Augmentation par variables temporelles et perturbation gaussienne — Phase 6

```

# Etape 1 : Expansion temporelle sur 3 periodes x 5 annees
time_periods = [
    ('electorales_2012_2017', 2012, 2017),
    ('indicateurs_2016_2020', 2016, 2020),
    ('securite_2016_2020', 2016, 2020),
]
dfs_temporal = [df_augmented.copy()]
for period_name, year_start, year_end in time_periods:
    for year in range(year_start, year_end + 1):
        df_year = df_augmented.copy()
        df_year['periode'] = period_name

```

```

        df_year['annee']    = year
        dfs_temporal.append(df_year)
# --> 429 012 lignes apres expansion temporelle

# Etape 2 : Perturbation gaussienne (bruit sigma=1% de l'ecart-type)
df_perturbed = df_final.copy()
for col in numeric_cols_agg:
    std_val = df_perturbed[col].std()
    noise    = np.random.normal(0, std_val * 0.01, size=len(df_perturbed))
    df_perturbed[col] = df_perturbed[col] + noise
df_perturbed['est_perturbation'] = 1
df_final['est_perturbation']     = 0

df_final = pd.concat([df_final, df_perturbed], ignore_index=True)
# --> 858 024 lignes au total (facteur x34 depuis les 25 574 lignes
    brutes)

```

Extrait 5 — Normalisation MinMax (Phase 7 ETL)

Listing B.5 – Normalisation Min-Max des colonnes numeriques — Phase 7

```

from sklearn.preprocessing import MinMaxScaler

# On exclut les colonnes binaires (0/1) de la normalisation
numeric_cols_to_scale = [
    col for col in numeric_cols_final
    if df_final_encoded[col].nunique() > 2
]
# 125 colonnes sur 127 numeriques sont normalisees

scaler = MinMaxScaler()
df_final_encoded[numeric_cols_to_scale] = scaler.fit_transform(
    df_final_encoded[numeric_cols_to_scale]
)
# Verification : mean=0.46, std=0.14 (distribution centree)

```

Extrait 6 — Entraînement XGBoost et validation croisée (Notebook ML)

Listing B.6 – Entraînement XGBoost avec cross-validation 5-fold — Notebook ML

```

from sklearn.model_selection import StratifiedKFold, cross_validate
import xgboost as xgb

skf = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)

```

```

model_xgb = xgb.XGBClassifier(
    max_depth=4,
    n_estimators=100,
    learning_rate=0.1,
    random_state=42,
    eval_metric='mlogloss',
    n_jobs=-1
)

cv_scores = cross_validate(
    model_xgb, X_train_scaled, y_train,
    cv=skf,
    scoring=['accuracy', 'precision_weighted',
            'recall_weighted', 'f1_weighted'],
    return_train_score=True
)

# Resultats CV :
# Accuracy moyenne : 76.59% (+/- 0.08%)
# Scores par fold : [76.47, 76.63, 76.57, 76.58, 76.71]

# Entrainement final sur l'ensemble complet d'entrainement
model_xgb.fit(X_train_scaled, y_train, verbose=False)

```

Extrait 7 — Mapping candidats / orientations politiques

Listing B.7 – Table de correspondance candidat → orientation — prediction_elections_NA.py

```

ORIENTATION_MAP = {
    # 2022
    "MACRON": "Centre",
    "LE_PEN": "Extreme_Droite",
    "MELENCHON": "Extreme_Gauche",
    "ZEMMOUR": "Extreme_Droite",
    "PECRESSE": "Droite",
    "JADOT": "Gauche",
    "LASSALLE": "Centre",
    "DUPONT-AIGNAN": "Droite",
    "HIDALGO": "Gauche",
    "POUTOU": "Extreme_Gauche",
    "ARTHAUD": "Extreme_Gauche",
    # 2017
    "FILLON": "Droite",
    "HAMON": "Gauche",
    # 2012
    "HOLLANDE": "Gauche",
    "SARKOZY": "Droite",
    "BAYROU": "Centre",
}

```

Extrait 8 — Export Delta Lake (Phase 8 ETL)

Listing B.8 – Sauvegarde multi-format — Phase 8 (CSV / Parquet / Delta Lake)

```
from deltalake.writer import write_deltalake

# Export CSV --> 2 215 MB
df_final_encoded.to_csv(export_final_path, index=False, encoding='utf-8')

# Export Parquet Snappy --> 293 MB (compression x7.5 vs CSV)
df_final_encoded.to_parquet(parquet_path, engine='pyarrow')

# Export Delta Lake --> 29.4 MB (compression x75 vs CSV)
# Version : delta-rs py-1.5.1
# 2 commits enregistrés dans _delta_log/
write_deltalake(export_delta_lake, data_fusionnee, mode='overwrite')
```